Traitement et exploitation des annuaires de propriétaires et des propriétés de Paris et du département de la Seine (1898, 1903, 1913, 1923)

Consortium Huma-num Paris Time Machine
Groupe Annuaires et adresses
25/11/2022

Frédérique Mélanie-Becquet, Alena Lapatniova, Carmen Brando, Gabriela Elgarrista

Le présent document présente les grandes étapes du traitement entrepris, entre 2019 et 2022, sur l'*Annuaire des propriétaires et des propriétés de Paris et du département de la Seine* ainsi que le résultat de ce travail (les livrables) effectué dans le contexte du groupe Annuaires et adresses du consortium Paris Time Machine d'Huma-num[1].

Contexte et objectif

Les annuaires et les répertoires anciens constituent une source riche d'informations sur un moment précis de la géographie des villes, mettant en rapport la distribution de l'espace avec des données socio-économiques ou professionnelles. Parmi eux, l'annuaire des propriétaires, une collection composée de trente-huit unités conservée par la Bibliothèque nationale pour laquelle aucune numérisation n'était disponible. Il s'agit d'une publication annuelle active entre 1894 et 1937 qui recense les adresses parisiennes et leurs propriétaires. Il se compose de deux grandes sections (voir figure après). La première partie de l'ouvrage comprend une liste alphabétique de tous les propriétaires de Paris et regroupe par propriétaire l'ensemble des propriétés de Paris. La seconde partie comporte la liste des rues de toutes les propriétés de Paris avec le nom et l'adresse personnelle du propriétaire. Cette liste précise si le domicile du propriétaire se trouve à Paris, en province ou à l'étranger. Nous avons choisi de travailler sur la seconde partie des annuaires afin de permettre une interrogation de la source par l'espace.

Notre travail a particulièrement consisté à rassembler, numériser, transcrire, structurer et enfin publier cette source sous une forme numérique en vue de faciliter son exploitation et réutilisation par des chercheur.es en histoire sociale et économique dont le terrain de recherche porte sur Paris. Pour ce faire, nous avons mis en œuvre une chaîne de traitement permettant d'obtenir, à partir d'un document numérisé (sous forme d'image), un document en format exploitable (donnée structurée).

Rassembler et numériser

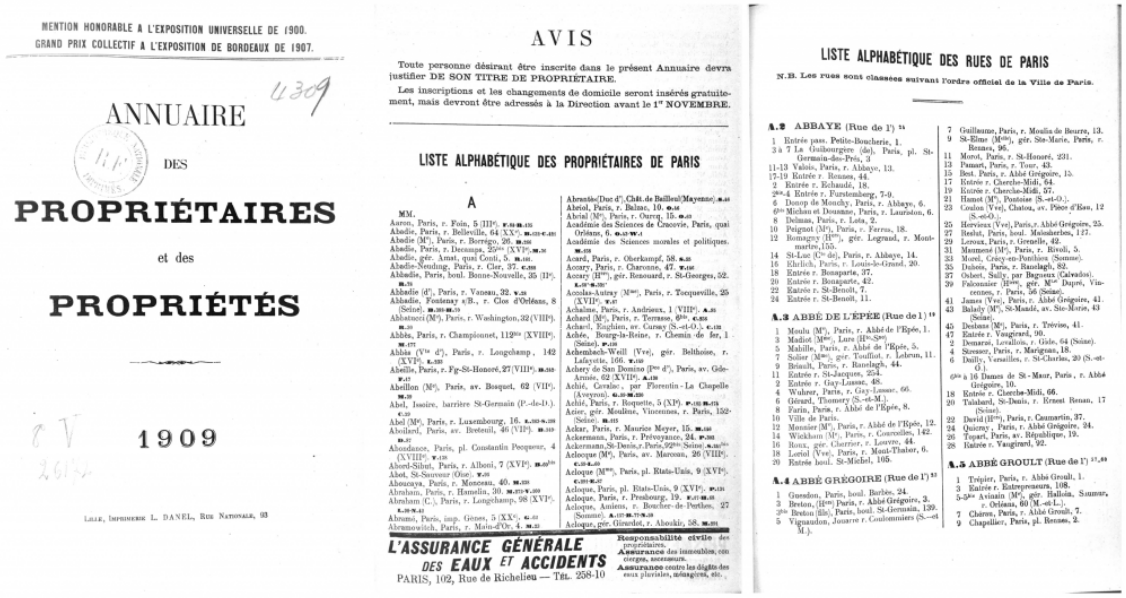
Un contrat de numérisation a été engagé avec la BNF pour commander des reproductions de la deuxième section de quatre volumes : 1898, 1903, 1913 et 1923, comprenant un total de 3 900 pages.

[1] Ce travail a reçu le soutien, d'une part, du Consortium sous la forme d'un contrat de vacation pour une durée de 2 mois, et d'autre part, du MESRI, sous la forme d'un partenariat avec l'INRIA, permettant la création d'un contrat post-doctoral pour une période de 12 mois (https://paris-timemachine.huma-num.fr/2020/01/30/dispositif-de-soutien-a-larchivistique-et-aux-humanites-numeriques-du-ministere/).

Ces choix répondent à plusieurs critères. La seconde partie de l'ouvrage est consacrée au recensement des propriétés parisiennes. Pour les années, l'objectif était de disposer de plages de dix années entre chaque publication. Ensuite, nous souhaitions arrêter une sélection permettant d'avoir un panorama de Paris avant et après la guerre. A la fin de l'été, le Département Images et prestations numériques de la BNF a livré quatre fichiers pdf, d'une résolution de 300 dpi. La couche de texte disponible dans ces documents, obtenue par passage d'OCR ABBYY FineReader 11, présentait de nombreuses erreurs de reconnaissance de caractères et ne tenait pas compte de la mise en page sur deux colonnes de l'annuaire. Une telle transcription était inutilisable.

Transcrire la source

Pour combler les défauts de la transcription existante, nous avons utilisé des outils d'apprentissage machine permettant de générer des transcriptions automatiques. La démarche consiste à alimenter un moteur de reconnaissance de texte à partir de données d'entraînement créées manuellement. Après


MENTION HONORABLE A L'EXPOSITION UNIVERSELLE DE 1900.
GRAND PRIX COLLECTIF A L'EXPOSITION DE BORDEAUX DE 1907.

ANNUAIRE
DES
PROPRIÉTAIRES
et des
PROPRIÉTÉS

1909

LILLE, IMPRIMERIE L. DANEL, RUE NATIONALE, 93

AVIS

Toute personne désirant être inscrite dans le présent Annuaire devra justifier DE SON TITRE DE PROPRIÉTAIRE.

Les inscriptions et les changements de domicile seront insérés gratuitement, mais devront être adressés à la Direction avant le 1er NOVEMBRE.

LISTE ALPHABÉTIQUE DES PROPRIÉTAIRES DE PARIS

A

L'ASSURANCE GÉNÉRALE DES EAUX ET ACCIDENTS
PARIS, 102, Rue de Richelieu — Tél. 258-10

LISTE ALPHABÉTIQUE DES RUES DE PARIS

N.B. Les rues sont classées suivant l'ordre officiel de la Ville de Paris.

A.2 ABBAYE (Rue de l')

A.3 ABBÉ DE L'ÉPÉE (Rue de l')

A.4 ABBÉ GRÉGOIRE (Rue de l')

A.5 ABBÉ GROULT (Rue de l')

plusieurs tests d'outils disponibles, le choix s'est porté sur Transkribus[2], une plateforme hébergée par l'Université d'Innsbruck, permettant la création des modèles HTR (Handwritten text recognition). Un modèle HTR+ a été créé à partir de 169 pages[3] (plus de 72 674 mots et 13 285 lignes) issues des éditions 1898 et 1923, pages pour lesquelles la segmentation et la transcription ont été revues et corrigées. Comme le volume de 1898 a des caractéristiques communes (la mise en page et les conventions typographiques) avec l'édition de 1903 et 1913, il n'a pas été nécessaire d'intégrer des pages pour ces

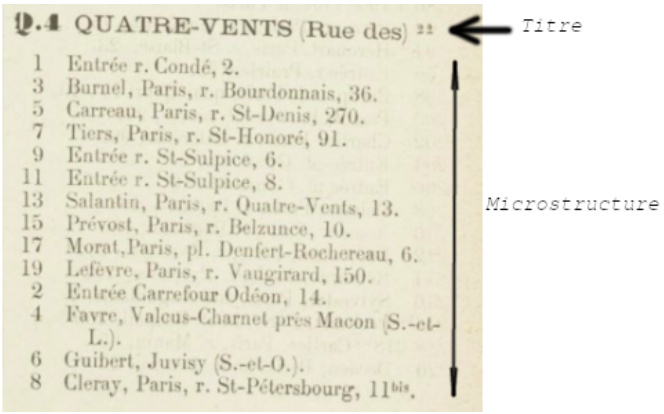
[2] https://transkribus.eu/Transkribus/

[3] Les données "vérité de terrain" ayant permis la création d'un modèle HTR+ sur Transkribus ont été deposées sur Nakala (http://dx.doi.org/10.34847/nkl.acb724xs) dans des formats permettant garder trace de la mise en forme comme XML Alto. Ce jeu de données est également référencé sur HTRUnited (http://dx.doi.org/10.34847/nkl.acb724xs) et sur le site de Transkribus (https://readcoop.eu/model/annuaires_propietaires_adr_paris_1898_1923/)

années au modèle. Le taux de CER (*Character Error Rate*[4]) est de 0.29%, taux encourageant ! Le modèle obtenu a été appliqué à l'ensemble des éditions (1903,1903, 1913 et 1923).

Structurer les textes par l'annotation

Nous avons procédé en 2 étapes, dans un premier temps nous avons travaillé sur les titres, dans un second temps sur la microstructure.



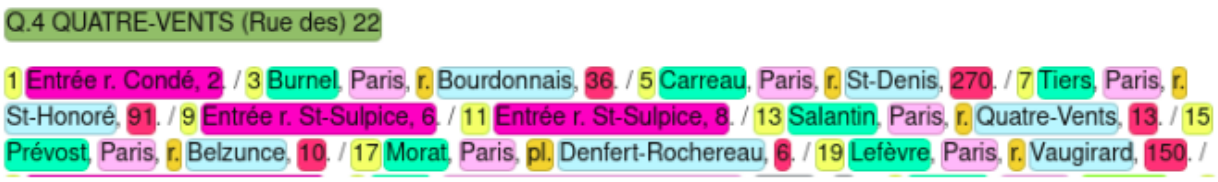
La première étape a consisté à extraire de la sortie texte obtenue en sortie de transcription, l'ensemble des titres de chacune des éditions (par utilisation de script). Pour chacune des éditions, nous avons créé un fichier csv listant les titres, et scindant ces derniers en un ensemble d'informations, de types : code_voie (lettre majuscule + chiffre), type_voie, quartiers.

Pour la seconde étape, nous avons établi la liste des entités qu'il nous semblait pertinent de repérer et récupérer dans le document. L'ensemble de ces entités est reporté dans le tableau ci-dessous (où la couleur de surbrillance appliquée à certaines entités correspond à l'annotation donnée en exemple pour l'entrée *QUATRE-VENTS* ci-dessous).

4 https://rechtsprechung-im-ostseeraum.archiv.uni-greifswald.de/word-error-rate-character-error-rate-how-to-evaluate-a-model/

étiquette	description
TITRE	Le titre de la microstructure
NUM	Numéro d'immeuble de la propriété
NUM_GLOB	Numéro (ou ensemble de numéros) référant à un même propriétaire
PART	Part de propriété (constr, terr, usufruit, nue-prop etc) qui est indiqué avant le nom du propriétaire
PERS	Nom du propriétaire
PRENOM	Prénom
ORG	Nom d'une organisation
STATUT	Vient après le nom, peut être Vve, héritiers, consorts,
VILLE	Ville du domicile.
VOIE	Nom de la voie (rue, rue de, boul etc) de l'adresse personnelle du propriétaire
RUE	Nom de la rue de l'adresse personnelle du propriétaire
NUM_PERS	Numéro d'immeuble de l'adresse perso du propriétaire
GER	pour Gérant et autres, peut contenir Nom et son adresse(rarement)
LOC	Département (si hors Paris) ou pays
SPATIAL	renvoie vers l'entrée sur une autre adresse

Nous avons annoté manuellement à l'aide de Prodigy[5] un ensemble de données, à savoir les pages 1167 à 1201 de l'édition 1898 (voir exemple dans la figure ci-dessous). A partir de ces annotations manuelles, nous avons créé un modèle de reconnaissance d'entités nommées (REN) à l'aide de la librairie Python Spacy[6] (pour lequel nous avons obtenu un f-score de 98.31) et avons propagé ce modèle à l'ensemble des éditions, et reconnu chacune des entités définies dans le tableau[7].



[5] https://prodi.gy/
[6] https://spacy.io/
[7] La description de la méthode employée est disponible dans un notebook : https://github.com/fmelanie/fromAnnotationsToModel/blob/main/annotationsToModel.ipynb

Nous avons ensuite fusionné les fichiers csv obtenus en étape une et les fichiers au format jsonl obtenus en étape deux, ce qui nous a permis de contrôler a minima la qualité des données (vérifier la présence ou l'absence du repérage automatique du titre, associer une microstructure à un titre).[8]

Stockage et mise à disposition des données (livrables)

L'ensemble des ressources (fichiers sources, transcriptions, et tableurs) créées et gérées dans ce travail sont sauvegardées dans l'espace sharedoc du Consortium. Le résultat final, autrement les données structurées sous forme de tableurs, ont été déposées dans une collection dédiée[9] sur Nakala.

Pour chacune des 4 années, trois fichiers tableurs existent contenant des niveaux de granularité différents :

- Ptm_1XXX_rues.csv, liste des rues du volume de l'année 1XXX - correspond au résultat de la première étape de structuration mentionnée ci-dessus.

A	B	C	D	E	F	G	H	I	J	K	L
ID	pagination	code_voie	lettre	num_voie	voie_fantome	complement_num	complement_nom_voie	code_voie_quartier	nom_voie	type_voie	quartiers
Q.4	1203	Q.4	Q	4				Q.4 QUATRE-VENTS (Rue des) 22	QUATRE-VENTS	rue	22

Dans ce tableur, les informations des colonnes *code_voie_quartier* (c'est-à-dire le *titre*) et *code_voie* sont scindées en plusieurs colonnes - en effet : *code_voie_quartier = code_voie + nom_voie + type voie + quartiers, code_voie = lettre + num_voie + complément_num* (complément num est de type *bis, ter*). La mention *voie fantôme* permet d'indiquer les noms de rue qui n'ont pas de code. La colonne *complément_nom_voie* contient quand à elle des informations diverses figurant sous le titre (par exemple : *Actuellement rue XXXX*). La colonne *pagination* donne le numéro de l'édition source. Quand à la colonne *ID*, elle donne un identifiant unique à la ligne dans l'ensemble du tableur, elles est le plus souvent identique à code_voie mais peut-être additionné d'un *ƒ* (s'il s'agit d'une voie fantôme) ou d'un chiffre permettant l'unicité de codes qui ne le sont pas.

- Ptm_1XXX_adresse.csv, liste d'adresses du volume de l'année 1XXX - correspond au résultat de la première et seconde étape mentionné ci-dessus.

[8] L'édition de 1898 contient 3576 titres, 31 n'ont pas été repérés automatiquement - pour l'édition de 1903 : 3982 titres, 68 non repérés, pour l'édition de 1913 : 4187 titres, 83 non repérés, pour l'édition de 1923 : 4325 titres, 285 non repérés.

[9] http://dx.doi.org/10.34847/nkl.f1d5052t

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
n_ord	code_vo	quartie	NUM	PART	PERS	PRENOM	ORG	STATU	VILLE	VOIE	RUE	NUM_PER	GER	LOC	SPATIAL
64413	Q.4	22	1	no	no	no	no	no	no	no	no	no	no	no	Entrée r. Condé, 2
64414	Q.4	22	3	no	Burnel	no	no	no	Paris	r.	Bourdonnais	36	no	no	no
64415	Q.4	22	5	no	Carreau	no	no	no	Paris	r.	St-Denis	270	no	no	no
64416	Q.4	22	7	no	Tiers	no	no	no	Paris	r.	St-Honoré	91	no	no	no
64417	Q.4	22	9	no	no	no	no	no	no	no	no	no	no	no	Entrée r. St-Sulpice, 6
64418	Q.4	22	11	no	no	no	no	no	no	no	no	no	no	no	Entrée r. St-Sulpice, 8
64419	Q.4	22	13	no	Salantin	no	no	no	Paris	r.	Quatre-Vents	13	no	no	no
64420	Q.4	22	15	no	Prévost	no	no	no	Paris	r.	Belzunce	10	no	no	no
64421	Q.4	22	17	no	Morat	no	no	no	Paris	pl.	Denfert-Roch	6	no	no	no
64422	Q.4	22	19	no	Lefèvre	no	no	no	Paris	r.	Vaugirard	150	no	no	no
64423	Q.4	22	2	no	no	no	no	no	no	no	no	no	no	no	Entrée Carrefour Odéon, 14
64424	Q.4	22	4	no	Favre	no	no	no	Valcus-Charr	no	no	no	no	S.-et- / L.	no
64425	Q.4	22	6	no	Guibert	no	no	no	Juvisy	no	no	no	no	S.-et-O.	no
64426	Q.4	22	8	no	Cleray	no	no	no	Paris	r.	St-Pétersbou	11bis	no	no	no
64427	Q.4	22	10-12	no	Pedon	no	no	Mme	Paris	r.	Quatre-Vents	10	no	no	no
64428	Q.4	22	14	no	Lassus (de)	no	no	no	Paris	boul.	Port-Royal	31	no	no	no
64429	Q.4	22	16	no	Lenoir	no	no	Mme	Beauvais	r.	Ste-Marguerit	30	no	Oise	no
64430	Q.4	22	18	no	Morin	no	no	no	Paris	boul.	Voltaire	26	no	no	no
64431	Q.4	22	20	no	no	no	no	no	no	no	no	no	no	no	Entrée r. Grégoire de Tours, 46
64432	Q.4	22	22	no	no	no	no	no	no	no	no	no	no	no	Entrée r. Seine, 95

Le champ *n_order* (identifiant unique) est un champ numérique permettant de conserver l'ordre de lecture du texte d'origine. Le champs *code_voie* permet de lier les informations à la ligne du tableur Ptm_1898_rues.csv ayant la même valeur code_voie. Seuls les champs *code_voie* et *quartiers* sont issus du tableur Ptm_1XXX_rues.csv.

- ptm_1XXX_augmentee.csv - contient les champs du tableur Ptm_1XXX_adresse.csv mais aussi l'ensemble des colonnes du tableur ptm_1XXX_rue.csv.

Cette version augmentée contient des colonnes qui ont étaient utiles à la constitution des données, ainsi que des colonnes interprétatives (par exemple : les colonnes *nb_immeubles* et *list_immeuble* donne respectivement le nombre d'immeuble auquel réfère le numéro de la rue et la liste de ces numéros. Si l'entité NUM est *10-14, nb_immeubles = 3* et *list_immeuble = [10, 12, 14]*). Il convient donc de manipuler avec beaucoup de précaution ces données.

- ptm_1XXX_noFind.csv - contient la référence des voies (le champ *ref voie*) et le nom des voies (le champ *code_voie_quartier*) qui n'ont pas eté trouvés et ne sont donc pas présentes dans les fichiers ptm_1XXX_rue.csv et ptm_1XXX_augmentee.csv. Cependant, si dans ces fichiers, les voies sont absentes, les informations référant à ces voies (les microstructures de type : NUM, PERS, etc.) existent et sont le plus souvent reportées de manières erronées à la voie précédente.

- ptm_1XXX.json - il s'agit d'une sérialisation en JSON des fichiers en format XML ALTO du vol. 1XXX de l'annuaire, ce fichier fait permet de faire le point entre les étapes décrites ci-dessus , "Transcrire la source" et "Structurer les textes par l'annotation".

En termes de licence de diffusion, en ce qui concerne les sources (les numérisations des annuaires), d'après le site de la BnF, l'utilisation académique ou scientifique (sans utilisation commerciale) « est libre et gratuite sous réserve de la mention de source : BnF ou Bibliothèque nationale de France ». La BnF met à disposition des clients, un document avec les conditions générales d'utilisation ainsi qu'un guide pour retrouver les ayants droits (les droits patrimoniaux expirent 70 ans après la mort de l'auteur). En ce qui concerne les données dérivées (transcriptions et données structurées), il a été convenu avec les services de la BNF dont le Datalab BNF, que la licence CC-BY-SA-NC[10] est adaptée pour leur diffusion et partage.

[10] Attribution-NonCommercial-ShareAlike 4.0 International
https://creativecommons.org/licenses/by-nc-sa/4.0/

Perspectives

Usages en histoire économique

Les *Annuaires des propriétaires et propriétés* constituent une source particulièrement prometteuse pour quiconque entend analyser l'évolution de la propriété immobilière au siècle dernier à Paris (et plus généralement). Dans le contexte du Projet Inégalités porté par Gilles Postel-Vinay (CRH-EHESS) et Jean-Laurent Rosenthal (Caltech), le besoin d'exploitation de cette source, complémentaire aux *Actes des décès des parisiens* et aux *déclarations de succession après décès*, est particulièrement important. Ce projet porte sur l'histoire de la richesse des parisiens au 19e et 20e siècles, l'idée étant de constituer un observatoire remarquablement précis et continu sur la distribution et la composition de la richesse individuelle (dans laquelle l'immobilier a une grande part). Les informations présentes dans les annuaires aideront particulièrement au classement par des historiens des immeubles de la capitale selon qu'ils appartiennent ou non à des particuliers. Parmi les données livrées, celles de 1898 sont déjà en train d'être améliorées et utilisées par ce projet. Enfin, l'ensemble des données structurées des 4 années seront également versées sur le portail de PROGEDO[11] et décrite vis à vis du standard DDI[12] et moissonnées par le Consortium of European Social Science Data Archives (CESSDA)[13] visant à des communautés d'historiens et d'économistes.

Communiquer et documenter les erreurs

Les tableurs obtenus sont un premier résultat, dont les chercheurs peuvent s'emparer. Cependant, en l'état, ces derniers nécessitent encore beaucoup de corrections et de travail. Des pistes sont envisagées afin d'améliorer les résultats obtenus automatiquement.

Tout d'abord, il serait possible à partir d'une édition corrigée manuellement - et nous aurons très bientôt une version propre, corrigée et relue de l'édition de 1898, d'établir un nouveau modèle d'annotation que nous pourrions propager ensuite à l'ensemble des éditions. Il est probable que l'ensemble des titres communs à l'édition de 1898 serait reconnu correctement dans les autres éditions, ce qui améliorerait substantiellement les résultats. En outre, à la lumière des corrections manuelles apportées, non seulement il serait possible de repenser la liste des entités à annoter (par exemple : ne plus isoler le prénom du propriétaire, bien peu d'entités sont concernées), mais aussi et surtout de comparer les données *propres* (relues et corrigées dans leur intégralité) aux données obtenues automatiquement - comparaison qui permettrait de typer et quantifier les erreurs de détection automatique. Ensuite, nous avons observé que la REN sur l'édition de 1923 était plus problématique. Il faudrait donc tester la mise en place d'un modèle pour cette édition. Deux pistes faciles et rapides à mettre en place, à tester.

Spatialiser l'annuaire par le géocodage des adresses

Une tentative de géocodage automatique[14] a été faite à partir de **14 000 adresses, de propriétés et de domiciles parisiens**, répertoriées dans **149 pages du volume de 1898**, en s'appuyant sur le géocodeur de

[11] https://data.progedo.fr/
[12] https://ddialliance.org/
[13] https://www.cessda.eu/
[14] Le processus de géocodage permet de transformer les localisations indirectes (adresses) en localisation directes (coordonnées).

la Base Adresse Nationale (BAN)[15] grâce à l'API REST disponible. La figure ci-dessous permet d'observer un premier essai de projection des points adresse sur une carte via QGIS[16]. 90.71 % d'adresses ont trouvé au moins une correspondance exacte. Ce géocodeur est sensible aux abréviations des types de voies qui ont souvent été opérées par les éditeurs de l'annuaire sur les adresses de domiciles. De même, nous avons effectué ce même test sur un géocodeur historique pour Paris, plus adapté à notre problématique, développé par l'équipe GeohistoricalData[17] de l'EHESS, aussi accessibles via un API REST. Il a été possible de trouver au moins une correspondance pour 92.96% d'adresses de propriétés. Ce chiffre se réduit au 78.94% dans le cas des domiciles parisiens : ces adresses sont ce qui rend difficile l'identification par le géocodeur. Le 13.91% restant n'a pas pu être géocodé. Ce géocodeur a été plus impacté par l'usage d'abréviations dans les adresses de domiciles. Que ce soit pour la BAN ou pour GeoHistoricalData, l'exactitude des localisations reste à vérifier manuellement.



Communications

- Mohamed Khemakhem, Carmen Brando, Laurent Romary, Frédérique Mélanie-Becquet, Jean-Luc Pinol. Fueling Time Machine: Information Extraction from Retro-Digitised Address Directories. JADH2018 "Leveraging Open Data", Sep 2018, Tokyo, Japan. Hal-01814189
- Gabriela Elgarrista, Frédérique Mélanie-Becquet, Carmen Brando. Annuaires de propriétaires de Paris : Vers une analyse socio-économique et spatiale de la population parisienne en 1898. Assises de l'AP en Humanités numériques spatialisées du GDR MAGIS, le 23 juin 2020.
- Gabriela Elgarrista, Frédérique Mélanie-Becquet, Carmen Brando, Mohamed Khemakhem, Laurent Romary, Jean-Luc Pinol, Pipeline to process and analyze Paris's old property address directories (XIXe - XXe), Poster CLARIN Bazaar, CLARIN Conference 2020, le 7 octobre 2020.
- Frédérique Mélanie-Becquet, Carmen Brando, Gabriela Elgarrista, Les annuaires de propriétaires de Paris : du format papier à l'analyse textuelle, Séminaire du GLISSS *L'usage des annuaires*

[15] https://adresse.data.gouv.fr/
[16] https://qgis.org/
[17] http://www.geohistoricaldata.org/

d'adresses autour de 1900, Regards croisés entre Paris et Strasbourg, Strasbourg, le 27 janvier 2022.